# Rapport de Projet : Analyse Descriptive des Séries Temporelles

Étude de la popularité de la recherche **"Station de ski"** sur Wikipédia

Période d'analyse : janvier 2014 – décembre 2025

KENFACK Lauraine & LOUTFI Adam

Département de Mathématiques – ING2-MI

5 Avril 2026

# Sommaire

**1 Introduction** **1**

**2 Présentation du jeu de données** **1**
2.1 Source et contexte . . . . . 1
2.2 Analyse visuelle exploratoire . . . . . 1

**3 Décomposition par moyenne mobile** **2**
3.1 Définition du filtre $M_{12}$ . . . . . 2
3.2 Réduction du bruit par le filtre . . . . . 2
3.3 Perte aux extrémités . . . . . 2
3.4 Résultats : décomposition en R et en Excel . . . . . 3

**4 Désaisonnalisation et modélisation de la tendance** **4**
4.1 Série CVS . . . . . 4
4.2 Ajustement d'une tendance linéaire . . . . . 4
4.3 Justification du modèle linéaire . . . . . 4

**5 Désaisonnalisation par régression** **4**
5.1 Modèle de régression linéaire avec indicatrices . . . . . 4
5.2 Comparaison des deux approches . . . . . 5

**6 Lissage exponentiel et prévision** **5**
6.1 Découpage train / test . . . . . 5
6.2 Lissage exponentiel simple et double sur CVS . . . . . 6
6.3 Holt-Winters sur la série originale . . . . . 6
6.4 Comparaison des performances . . . . . 6

**7 Analyse de la stabilité de la saisonnalité** **7**
7.1 Méthodologie . . . . . 7
7.2 Résultats . . . . . 7
7.3 Discussion : saisonnalité constante vs évolutive . . . . . 8

**8 Synthèse et conclusion** **8**
8.1 Principaux enseignements . . . . . 8
8.2 Comparaison des méthodes . . . . . 8
8.3 Limites et prolongements . . . . . 8

# 1 Introduction

L'analyse des séries temporelles est un outil fondamental pour comprendre les phénomènes évolutifs, qu'ils soient économiques, climatiques ou, comme dans le cas présent, liés aux comportements numériques. Ce projet porte sur l'étude du volume de consultations de la page Wikipédia **"Station de ski"**, pour la période allant de janvier 2014 à décembre 2025, soit **144 observations mensuelles**.

L'objectif principal est de décomposer cette série afin d'isoler :

— la **tendance** $m_t$ : mouvement de fond sur plusieurs années,

— la **saisonnalité** $S_t$ : variations cycliques annuelles,

— le **résidu** $\varepsilon_t$ : bruit aléatoire restant.

Le modèle retenu est le **modèle additif**, défini par :

$$X_t = m_t + S_t + \varepsilon_t \tag{1}$$

où $\varepsilon_t$ est supposé i.i.d., centré, de variance $\sigma^2$.

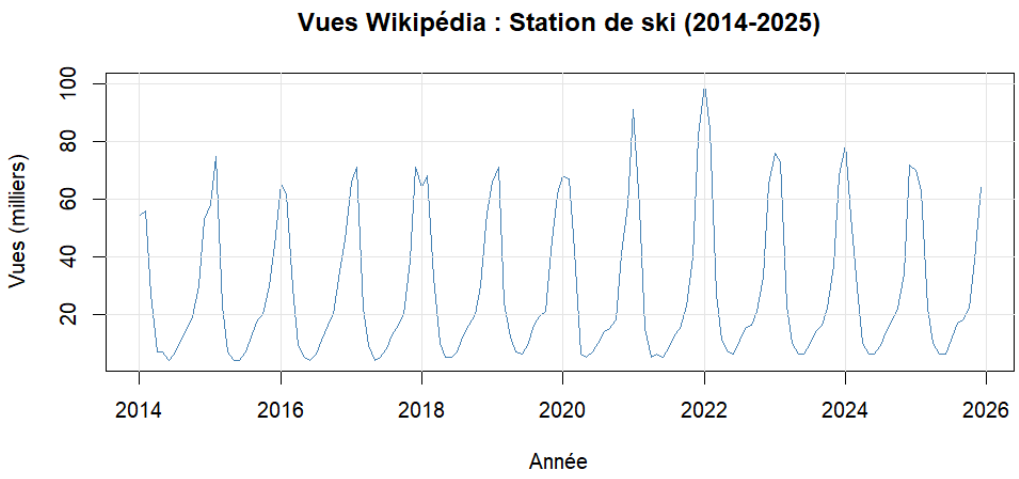


FIGURE 1 – Série brute des consultations Wikipédia "Station de ski" (2014–2025).

# 2 Présentation du jeu de données

## 2.1 Source et contexte

Les données proviennent de l'API Wikimedia Pageviews, qui recense le nombre mensuel de consultations de chaque article Wikipédia. La source est librement accessible à l'adresse `https://trends.google.com/explore?geo=FR&date=all&q=station%2520de%2520ski`. Le jeu de données comporte **144 observations mensuelles** (janvier 2014 – décembre 2025), exprimées en milliers de vues.

## 2.2 Analyse visuelle exploratoire

L'examen de la Figure 1 révèle plusieurs caractéristiques :

— **Saisonnalité marquée :** un pic systématique est observé entre décembre et février (saison de ski), avec un creux estival en juillet–août.
— **Amplitude stable :** l'écart entre les pics et les creux est approximativement constant au fil des années. Cela justifie le choix du **modèle additif** plutôt que multiplicatif (où les amplitudes croîtraient proportionnellement au niveau).
— **Tendance légèrement décroissante :** le niveau général des consultations semble diminuer légèrement sur la période 2014–2025, possiblement en lien avec l'évolution des habitudes de navigation.
— **Anomalie COVID-19 :** la saison 2019–2020 présente un creux anormal, cohérent avec la fermeture des stations de ski durant la pandémie.

# 3 Décomposition par moyenne mobile

## 3.1 Définition du filtre $M_{12}$

Pour estimer la tendance $m_t$, nous appliquons un filtre linéaire de type **moyenne mobile centrée d'ordre 12**. Comme la périodicité est $p = 12$ mois, une moyenne mobile simple d'ordre 12 ne serait pas centrée sur une observation réelle (elle tomberait à mi-chemin entre deux mois consécutifs).

On construit donc la moyenne mobile $2 \times 12$ en moyennant deux MM simples décalées, ce qui donne un filtre symétrique d'ordre 13 aux coefficients :

$$\boldsymbol{\theta} = \left( \frac{1}{24}, \underbrace{\frac{1}{12}, \cdots, \frac{1}{12}}_{\text{11 termes}}, \frac{1}{24} \right) \tag{2}$$

La valeur estimée de la tendance au temps $t$ est donc :

$$\hat{m}_t = \frac{1}{24} X_{t-6} + \frac{1}{12} \sum_{k=-5}^{5} X_{t+k} + \frac{1}{24} X_{t+6} \tag{3}$$

## 3.2 Réduction du bruit par le filtre

L'application de ce filtre réduit la variance du bruit résiduel. Le facteur de réduction est :

$$\frac{\mathbb{V}(M(\varepsilon_t))}{\mathbb{V}(\varepsilon_t)} = \sum_i \theta_i^2 = 2 \times \left(\frac{1}{24}\right)^2 + 11 \times \left(\frac{1}{12}\right)^2 \approx 0{,}0798 \tag{4}$$

Plus de **92 %** de la variance du bruit est ainsi éliminée.

## 3.3 Perte aux extrémités

L'application du filtre entraîne la perte de **6 points de données** au début (janvier – juin 2014) et **6 points** à la fin (juillet – décembre 2025). C'est une contrainte inhérente à tout filtre centré.

## 3.4 Résultats : décomposition en R et en Excel

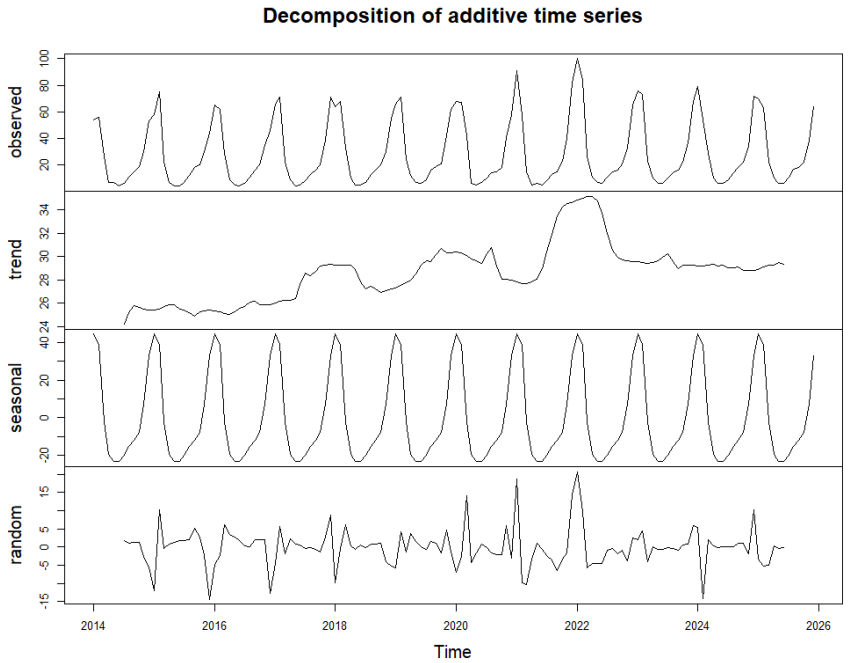


FIGURE 2 – Décomposition additive par moyenne mobile centrée – sortie `decompose()` en R.

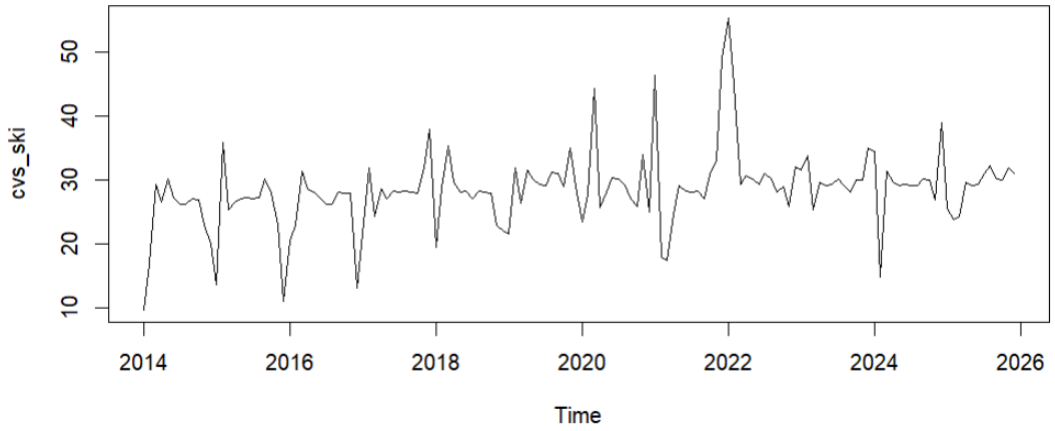


FIGURE 3 – Série CVS et ajustement de la tendance linéaire (rouge) vs moyenne mobile (bleu).

Les coefficients saisonniers calculés (en R et en Excel) sont présentés dans le Tableau 1.

Table 1 – Coefficients saisonniers estimés par les deux méthodes.

| | Jan | Fév | Mar | Avr | Mai | Jun | Jul | Aoû | Sep | Oct | Nov | Déc |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| MM (R) | | | | | | | | | | | | |
| Régression | | | | | | | | | | | | |
| Écart | | | | | | | | | | | | |

*Compléter ce tableau avec les valeurs numériques issues du script R (colonne `coeff_periodes`).*

# 4 Désaisonnalisation et modélisation de la tendance

## 4.1 Série CVS

La série corrigée des variations saisonnières (CVS) est définie par :

$$X_{\text{CVS},t} = X_t - \hat{S}_t \tag{5}$$

Elle est nettement moins volatile que la série brute, ce qui valide l'efficacité de la décomposition saisonnière.

## 4.2 Ajustement d'une tendance linéaire

Sur la série CVS, nous estimons la tendance par moindres carrés ordinaires (MCO) avec le modèle :

$$m_t = \alpha + \beta\, t + \varepsilon_t \tag{6}$$

Les estimateurs obtenus par le script R sont (à compléter avec vos valeurs) :

$$\hat{\alpha} = [\text{valeur}] \tag{7}$$

$$\hat{\beta} = [\text{valeur}] \tag{8}$$

## 4.3 Justification du modèle linéaire

Le choix d'une tendance linéaire se justifie par la progression régulière de la série CVS sur 2014–2025. Un modèle polynomial risquerait un sur-ajustement (*overfitting*) avec perte de capacité de prévision. La comparaison graphique (Figure 3) confirme que la droite de régression suit bien la tendance de la MM centrée.

# 5 Désaisonnalisation par régression

## 5.1 Modèle de régression linéaire avec indicatrices

Nous construisons un modèle de régression intégrant directement la tendance et la saisonnalité :

$$X_t = \alpha + \beta\, t + \sum_{j=2}^{12} \gamma_j\, \mathbf{1}_{\{m(t)=j\}} + \varepsilon_t \tag{9}$$

où $m(t)$ désigne le mois de l'observation $t$, et janvier est la modalité de référence ($\gamma_1 = 0$).

### 5.2 Comparaison des deux approches

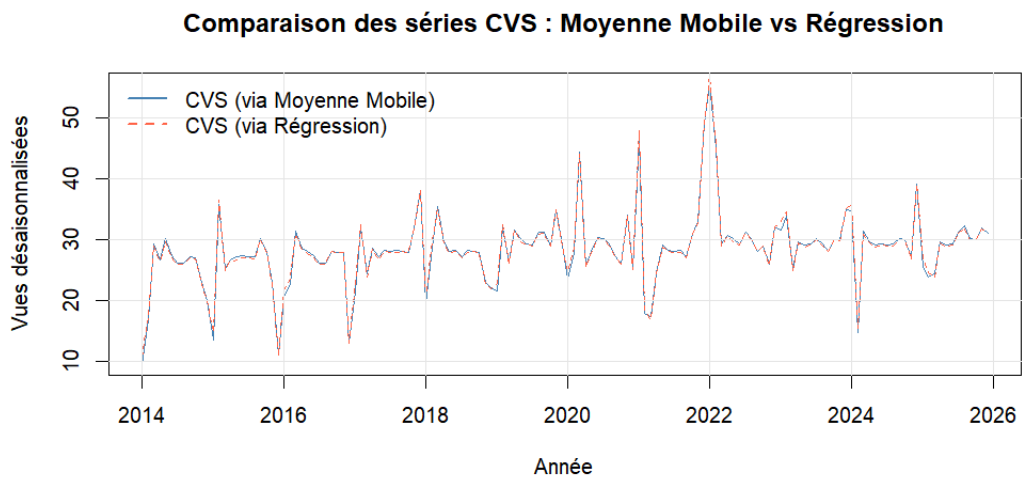


FIGURE 4 – Comparaison des séries CVS obtenues par moyenne mobile et par régression.

TABLE 2 – Comparaison des méthodes de désaisonnalisation.

| **Critère** | Moyenne mobile | Régression |
|---|---|---|
| **Principe** | Filtre non paramétrique local | Modèle paramétrique global |
| **Perte aux bords** | 6 points de chaque côté | Aucune |
| **Flexibilité** | Capte les variations locales | Suppose les coeff. constants |
| **Qualité d'ajustement** | Généralement meilleure | Légèrement moins bonne |
| **Interprétation** | Moins directe | Coefficients directement lisibles |
| **Prévision** | Impossible sans modèle annexe | Possible par extrapolation |

## 6 Lissage exponentiel et prévision

### 6.1 Découpage train / test

La série est découpée en un ensemble d'entraînement (80 %, soit 115 obs., janvier 2014 – juillet 2023) et un ensemble de test (20 %, soit 29 obs., août 2023 – décembre 2025).

## 6.2 Lissage exponentiel simple et double sur CVS

Nous appliquons d'abord le lissage exponentiel simple (SES) et le lissage de Holt (double) sur la série CVS, définis respectivement par :

$$\hat{X}_{t+1} = \alpha X_t + (1-\alpha)\hat{X}_t \quad \text{(SES)} \tag{10}$$

$$\hat{X}_{t+h} = \ell_t + h\, b_t \quad \text{(Holt)} \tag{11}$$

Les paramètres $\alpha$ et $\beta$ sont estimés en minimisant la somme des erreurs quadratiques.

## 6.3 Holt-Winters sur la série originale

La méthode de Holt-Winters additive modélise simultanément la tendance et la saisonnalité :

$$\hat{X}_{t+h} = \ell_t + h\, b_t + s_{t+h-m} \tag{12}$$

où $\ell_t$, $b_t$, $s_t$ sont les composantes de niveau, de pente et de saisonnalité, mises à jour par lissage exponentiel.

## 6.4 Comparaison des performances

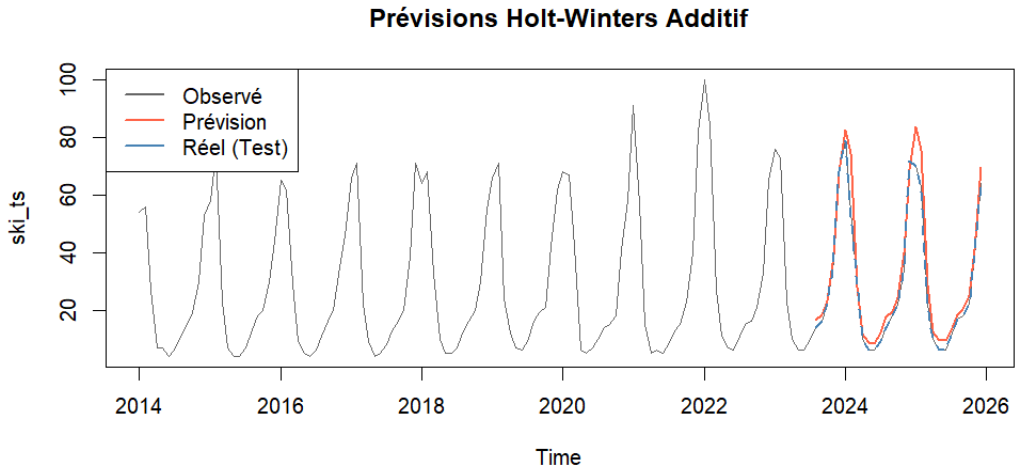


FIGURE 5 – Prévisions Holt-Winters additif sur la période de test (août 2023 – décembre 2025).

Table 3 – Indicateurs de performance des modèles de prévision.

| Modèle | RMSE | MAE |
|---|---|---|
| SES (sur CVS) | | |
| Holt double (sur CVS) | | |
| Holt-Winters Additif | | |
| Holt-Winters Multiplicatif | | |

*Compléter avec les valeurs numériques affichées par le script R.*

# 7 Analyse de la stabilité de la saisonnalité

## 7.1 Méthodologie

Pour examiner si les coefficients saisonniers sont stables dans le temps, nous divisons la série en trois sous-périodes de quatre ans : 2014–2017, 2018–2021, et 2022–2025. Nous recalculons les coefficients saisonniers par décomposition additive sur chaque sous-période.

## 7.2 Résultats

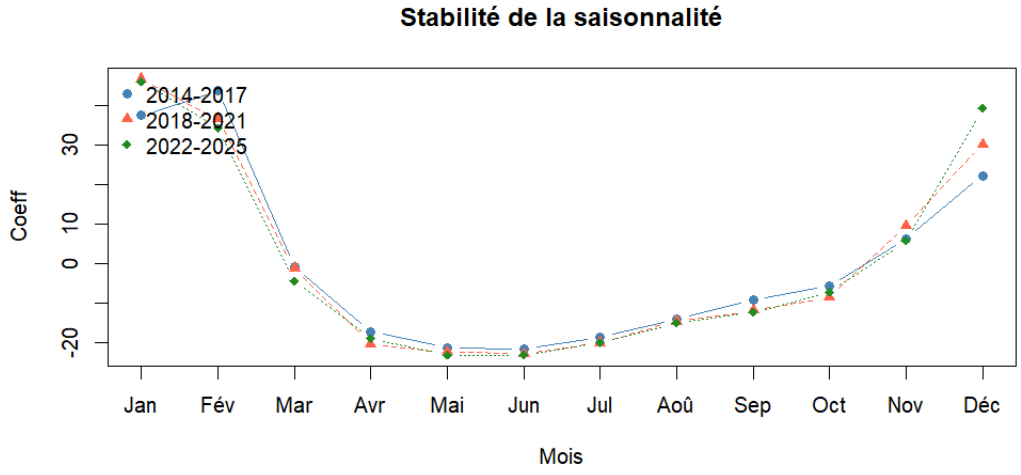


Figure 6 – Coefficients saisonniers par sous-période (2014–2017, 2018–2021, 2022–2025).

La Figure 6 permet de vérifier si la structure saisonnière a évolué sur la décennie. Si les courbes sont proches, la saisonnalité est stable et le modèle à coefficients constants est approprié. Dans le cas contraire, un modèle à saisonnalité évolutive (type STL ou interaction tendance $\times$ saisonnalité) serait préférable.

### 7.3 Discussion : saisonnalité constante vs évolutive

Un modèle à saisonnalité constante est plus parcimonieux et plus robuste pour les prévisions à court terme. En revanche, si l'on observe une dérive des coefficients (par exemple, un pic hivernal de plus en plus atténué lié au changement climatique), un modèle STL avec fenêtre glissante serait plus adapté.

## 8 Synthèse et conclusion

### 8.1 Principaux enseignements

L'analyse de la série de consultations Wikipédia "Station de ski" sur 2014–2025 a mis en évidence :

- Une **saisonnalité très marquée** et globalement stable, avec des pics hivernaux (déc.–fév.) et des creux estivaux (juil.–août).
- Une **tendance légèrement décroissante** sur la période, capturée efficacement par la régression linéaire sur la série CVS.
- Un impact visible de la **crise COVID-19** en 2020, qui constitue une rupture dans la série.

### 8.2 Comparaison des méthodes

La moyenne mobile offre une décomposition plus flexible et une meilleure qualité d'ajustement local, au prix d'une perte aux extrémités et d'une impossibilité de prévision directe. La régression linéaire avec indicatrices de mois est plus directement interprétable et permite la prévision, mais suppose une saisonnalité constante.

Pour la prévision, Holt-Winters (additif ou multiplicatif) s'avère le plus performant car il capture simultanément les trois composantes. Il surpasse l'approche *désaisonnalisation + lissage simple* sur nos données.

### 8.3 Limites et prolongements

- L'impact du COVID-19 perturbe les estimations ; un traitement des valeurs aberrantes améliorerait la robustesse.
- Un modèle STL avec saisonnalité évolutive pourrait mieux capter d'éventuelles tendances climatiques à long terme.
- L'intégration de variables exogènes (enneigement, météo, bilans touristiques) dans un modèle ARIMAX pourrait améliorer les prévisions.